

ESTUDO DO ALGORITMO $\text{SPSO}_{\text{AP+AD}}$ EM OTIMIZAÇÃO DINÂMICA CONTÍNUA

SIN5006 – INTELIGÊNCIA COMPUTACIONAL

Prof. Dra. Patrícia Oliveira

Aluno Pável Emmanuel Pereira Lelis

DEFINIÇÃO DO PROBLEMA: O Desafio da Otimização Dinâmica

Problemas de Otimização Dinâmica (DOPs), onde a função objetivo, restrições ou ambos mudam ao longo do tempo, são prevalentes em diversas áreas da engenharia e ciência.

$$\begin{aligned} \text{Maximize : } & f^{(t)}(\mathbf{x}) = f(\mathbf{x}, \alpha^{(t)}), \mathbf{x} = \{x_1, x_2, \dots, x_d\} \\ \text{Subject to : } & \mathbf{x} \in \mathbb{X} : \mathbb{X} = \{\mathbf{x} \mid Lb_i \leq x_i \leq Ub_i\}, i \in \{1, 2, \dots, d\}, \\ & g_j^{(t)}(\mathbf{x}) \leq 0, j \in \{1, 2, \dots, \hat{g}\}, \\ & h_k^{(t)}(\mathbf{x}) = 0, k \in \{1, 2, \dots, \hat{h}\}, \end{aligned}$$

DEFINIÇÃO DO PROBLEMA : O Desafio da Otimização Dinâmica

- Rastreamento de Ótimos Móveis: O principal desafio não é apenas encontrar o ótimo global, mas segui-lo à medida que ele muda de posição e/ou valor na paisagem de fitness.
- O que era uma excelente solução em $t-1$ pode ser medíocre ou ruim em t .
- Algoritmos de otimização são projetados para convergir. Em DOPs, essa convergência se torna um problema quando convergir para um ótimo que se tornou obsoleto após uma mudança.
- O algoritmo precisa reagir rápido e encontrar (ou se aproximar) do novo ótimo antes que o ambiente mude novamente.
- Recursos Computacionais Limitados: Frequentemente, há um número finito (e às vezes pequeno) de avaliações de fitness ou tempo de processamento disponível *entre* as mudanças ambientais

DEFINIÇÃO DO PROBLEMA : O Desafio da Otimização Dinâmica

Yazdani et al (2023) comentam que muitos problemas do mundo real são inerentemente dinâmicos. Exemplos:

- Engenharia: Controle adaptativo de processos.
- Logística: Roteamento de veículos em tempo real.
- Finanças: Gestão de portfólios, precificação dinâmica.
- Robótica: Navegação em ambientes com obstáculos móveis.
- Telecomunicações: Alocação de recursos de rede.

Os autores discutem que algoritmos de otimização tradicionais, projetados para ambientes estáticos, frequentemente falham em DOPs devido a desafios como convergência para ótimos obsoletos, perda de diversidade populacional e gestão inadequada de recursos computacionais limitados entre mudanças ambientais.

MÉTODO SPSO_{AP+AD}: Visão Geral

Geração de Indivíduos e Espécies

- Utiliza Particle Swarm Optimization (PSO) com fator de convergencia para otimização local.
- Clustering baseado em Posição (\mathbf{P}_{best}) e Fitness, feito a cada iteração.
- Indivíduo com melhor fitness vira "semente"; adiciona-se os n-1 vizinhos mais próximos para formar a espécie.
- A \mathbf{P}_{best} da semente da espécie serve como \mathbf{G}_{best} (atrator) para os membros daquela espécie.

Classificação de espécies

- **Distância Espacial:** As espécies são classificadas de acordo com a dispersão relacionado a distancia de cada membro ao Pbest da espécie. ς_i
- **Tracker:** Espécie convergida (localizou um pico). Critério: $\varsigma_i \leq r_{track}$. Responsável por seguir o pico.
- **Non-Tracker:** Espécie não convergida ($\varsigma_i > r_{track}$). Responsável por explorar.
- Limiar r_{track} : É adaptativo, definido como a severidade da mudança estimada ($\hat{\$}$) para garantir que a re-diversificação pós-mudança não reclassifique um tracker como non-tracker

MÉTODO SPSO_{AP+AD}: Visão Geral

Componente AP: Mecanismos de Adaptação Populacional

Incremento de Indivíduos (+):

Se todas as espécies atuais convergiram ($\forall i, \varsigma_i \leq \mathbf{r}_{\text{generate}}$) E $N < N_{\text{max}}$: Adiciona m (**NewlyAddedPopulationSize** = 5) novas partículas aleatórias à população.

Redução (-):

Se Distância($\mathbf{P}_{\text{best}}(\text{semente}_i), \mathbf{P}_{\text{best}}(\text{semente}_j)$) $< \mathbf{r}_{\text{excl}}$: Remove todos os indivíduos da espécie cuja semente tem pior fitness.

Anti-Convergência (=):

SE $N = N_{\text{max}}$ (limite de espécies atingido) E todas as espécies convergiram ($\forall i, \varsigma_i \leq \mathbf{r}_{\text{generate}}$): Em vez de adicionar, reinicializa aleatoriamente os indivíduos da espécie com a pior semente.

Raios Adaptativos: Os limiares $\mathbf{r}_{\text{generate}}$ e \mathbf{r}_{excl} são ajustados a cada iteração com base no número atual de espécies N e nos limites do espaço de busca

MÉTODO SPSO_{AP+AD}: Visão Geral

Componente AD: Objetivo e Mecanismo

Objetivo AD:

Alocar recursos computacionais (avaliações de fitness) eficientemente. Evitar "super exploração" desnecessária por espécies tracker que já estão suficientemente próximas de seus picos.

Mecanismo de desativação

- Aplica-se apenas a espécies classificadas como Tracker.
- A cada iteração, uma espécie tracker i é desativada se seu tamanho espacial ς_i for menor ou igual ao raio de desativação adaptativo \mathbf{r}_a (**CurrentDeactivation**).
- Espécies desativadas "hibernam": não executam o passo de otimização PSO naquela iteração, economizando avaliações de fitness.
- Exceção Importante: A espécie tracker com a melhor semente global (o líder geral) nunca é desativada, garantindo que a melhor solução encontrada continue sendo refinada.

MÉTODO $\text{SPSO}_{\text{AP+AD}}$: Visão Geral

Adaptação a Mudança

Ocorre imediatamente após uma mudança ambiental ser detectada.

Passos Executados:

1. Estimar Severidade ($\hat{\mathbf{S}}$): Calcula a distância média que as sementes dos trackers se moveram entre os dois ambientes anteriores. $\hat{\mathbf{S}}$ informa a intensidade da mudança.
2. Aumentar Diversidade: Reposiciona aleatoriamente os membros (não a semente) das espécies tracker numa hiper-esfera em torno da \mathbf{P}_{best} da semente, com raio proporcional a $\hat{\mathbf{S}}$. Isso ajuda a re-explorar a área onde o pico pode ter se movido.
3. Reavaliar Todas as Partículas: Calcula o fitness de todas as partículas na nova paisagem de fitness. Essencial para lidar com a memória obsoleta.
4. Resetar Pbest: O \mathbf{P}_{best} de cada partícula é atualizado para sua posição/fitness atuais após a reavaliação.
5. Atualizar/Resetar Parâmetros Adaptativos: $\hat{\mathbf{S}}$ é atualizado, \mathbf{r}_a é resetado para \mathbf{r}_{amax} (baseado no novo $\hat{\mathbf{S}}$), β é resetado para 1, e $\mathbf{r}_{\text{track}}$ é atualizado para $\hat{\mathbf{S}}$.

O QUE FOI PROMETIDO x O QUE FOI OBTIDO

Prometido como primeira entrega.

Um código-fonte funcional em Python, Julia ou Matlab do algoritmo de GMPB.

Alcançado como primeira entrega.

Implementação em python para cenário 1. Implementação de todos os códigos Matlab em Python. Principais bibliotecas utilizadas Numpy Scipy e Matplotlib

Dificuldades

Para entendimento do tema e do algoritmo é necessário uma grande atenção a interação de diversos conceitos e parâmetros. que são adaptativos e interdependentes. Entender como esses valores se conectam e influenciam dinamicamente os componentes está sendo um grande desafio.

Os códigos para a replicação do cenário 2 não foram disponibilizados pelos autores, dessa forma o trabalho seguirá com o cenário 1.

O QUE FOI PROMETIDO x O QUE FOI OBTIDO

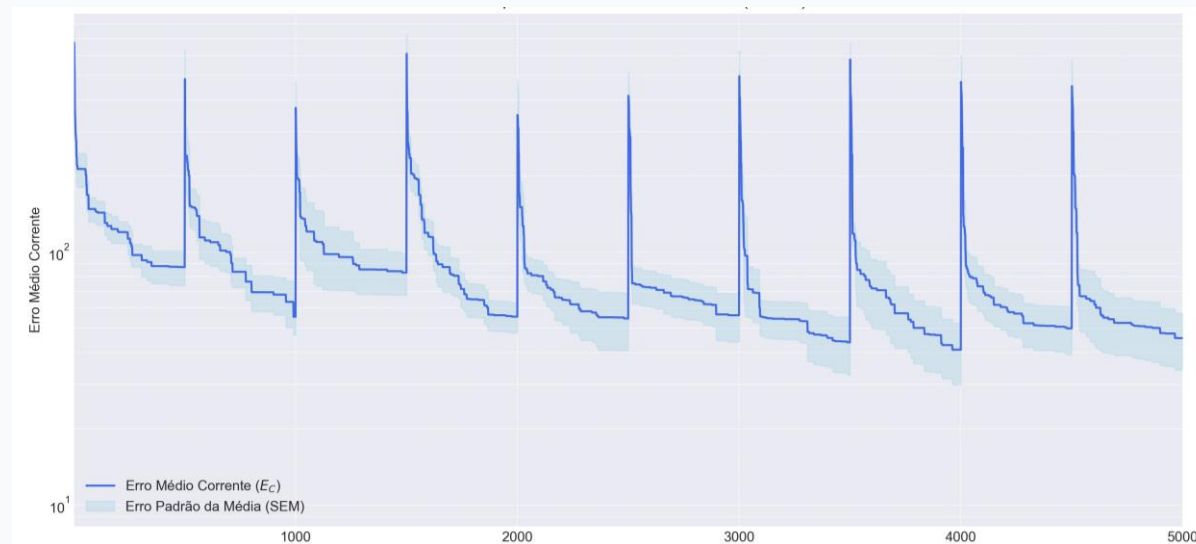
Arquivo MATLAB	Arquivo Python	Descrição Breve da Função Python
Main.m	run_experiment.py	Define parâmetros do experimento, chama o runner, processa resultados finais, gera gráficos.
main_ASPSO_GMPB.m	aspsogmpb_runner.py	Orquestra múltiplas runs, inicializa problema/otimizador, gerencia loop principal, coleta dados.
BenchmarkGenerator_ASPSO_GMPB.m	gmpb_benchmark.py	Gera a estrutura problem para GMPB Cenário 1.
fitness_ASPSO_GMPB.m	fitness_eval.py	Calcula fitness para GMPB Cenário 1, atualiza FEs/Erro/Mudança.
InitializingOptimizer_ASPSO_GMPB.m	aspsogmpb_utils.py	Inicializa o estado de uma única partícula (posição, Pbest, etc.), chama fitness_func.
CreatingSpecies.m	aspsogmpb_utils.py	Agrupa partículas em espécies com base em Pbest (posição/fitness).
Optimization_ASPSO_GMPB.m	aspsogmpb_core.py	Executa uma iteração do ASPSO+AP+AD (cria espécies, exclusão, AD, PSO, AP).
Reaction_ASPSO_GMPB.m	aspsogmpb_core.py	Executa a resposta do algoritmo a uma mudança ambiental detectada.

DESENHO EXPERIMENTAL

Função de estudo (Benchmarking GMPB)

Parameter	Symbol	Value(s) in Scenario 1
Number of sub-functions	q	1
Sub-function dimensionality	d_i	{5}
Shift severity	\tilde{s}	1, 2, 5
Numbers of promising regions	m	10, 25, 50, 100, 200
Evaluations between changes	ϑ	500, 1,000, 2,500, 5,000
Dimension	d	5
Height severity	\tilde{h}	7
Width severity	\tilde{w}	1
Weight of sub-function i	ω_i	1
Angle severity	$\tilde{\theta}$	$\pi/9$
Irregularity parameter τ severity	$\tilde{\tau}$	0.2
Irregularity parameter η severity	$\tilde{\eta}$	2
Search range	$[Lb, Ub]^d$	$[-100, 100]^d$
Height range	$[h_{\min}, h_{\max}]$	[30, 70]
Width range	$[w_{\min}, w_{\max}]^d$	$[1, 12]^d$
Angle range	$[\theta_{\min}, \theta_{\max}]$	$[-\pi, \pi]$
Irregularity parameter τ range	$[\tau_{\min}, \tau_{\max}]$	$[-1, 1]$
Irregularity parameter η range	$[\eta_{\min}, \eta_{\max}]$	$[-20, 20]$
Number of environments	T	100

Aproximação para visualização.



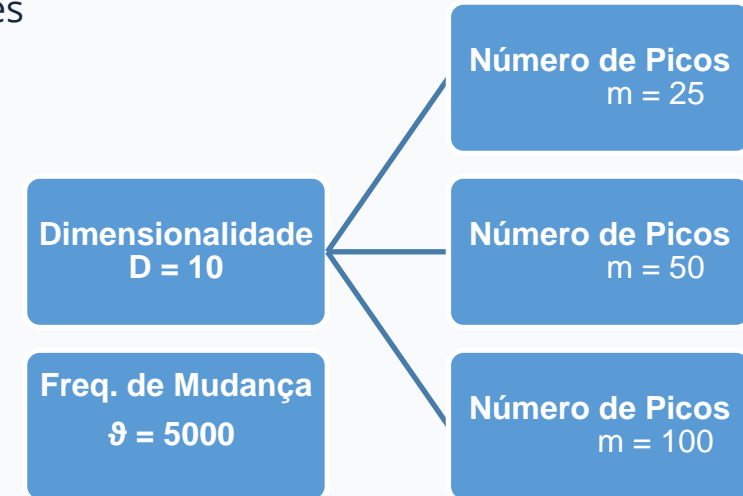
DESENHO EXPERIMENTAL

Função de estudo (Benchmarking GMPB)

Parameter	Symbol	Value(s) in Scenario 1
Number of sub-functions	q	1
Sub-function dimensionality	d_i	{5}
Shift severity	\tilde{s}	1, 2, 5
Numbers of promising regions	m	10, 25, 50, 100, 200
Evaluations between changes	ϑ	500, 1,000, 2,500, 5,000
Dimension	d	5
Height severity	\tilde{h}	7
Width severity	\tilde{w}	1
Weight of sub-function i	ω_i	1
Angle severity	$\tilde{\theta}$	$\pi/9$
Irregularity parameter τ severity	$\tilde{\tau}$	0.2
Irregularity parameter η severity	$\tilde{\eta}$	2
Search range	$[Lb, Ub]^d$	$[-100, 100]^d$
Height range	$[h_{\min}, h_{\max}]$	[30, 70]
Width range	$[w_{\min}, w_{\max}]^d$	$[1, 12]^d$
Angle range	$[\theta_{\min}, \theta_{\max}]$	$[-\pi, \pi]$
Irregularity parameter τ range	$[\tau_{\min}, \tau_{\max}]$	$[-1, 1]$
Irregularity parameter η range	$[\eta_{\min}, \eta_{\max}]$	$[-20, 20]$
Number of environments	T	100

Grafo do Experimento.

31 Replicações



- **Benchmarking GMPB:** Generalized Moving Peaks Benchmark na configuração não-modular (1 função global) e homogênea.
- **Dimensionalidade:** O espaço de busca tem 5 dimensões.
- **Número de Picos:** Testa o algoritmo com diferentes níveis de multimodalidade (complexidade da paisagem). Cada valor representa uma execução separada.
- **Frequência da Mudança:** O ambiente muda a cada 5000 avaliações de fitness (FEs). Indica um tempo computacional antes da alteração do problema.

DISCUSSÃO E RESULTADOS*

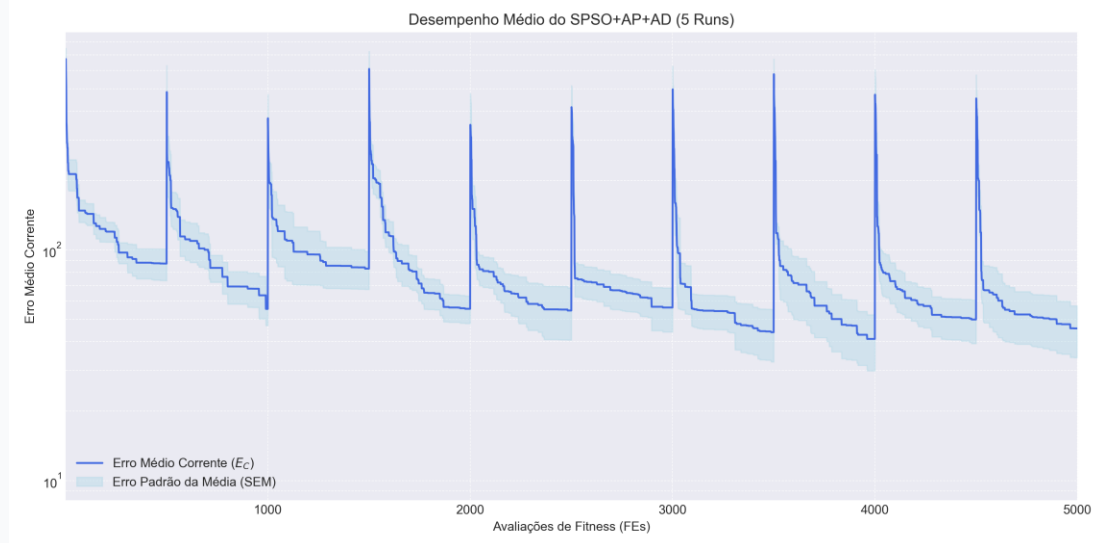


```

def process_and_plot_histories(run_results, max_evals_total, run_number):
    interpolated_runs[1, :] = interp_func(common_fe_axis)
    elif len(run_fes) == 1: # Apenas um ponto de dados
        # Encontra o índice correspondente ao FE e preenche a partir dele
        fe_idx = int(run_fes[0]) - 1
        if 0 <= fe_idx < max_evals_total:
            interpolated_runs[1, fe_idx:] = run_values[0] # Preenche o ponto em diante
        # Se run_fes estiver vazio, a linha permanece NaN

    all_runs_data_interp[metric_key] = interpolated_runs

    if not history_data_available:
        print("Nenhum dado histórico válido encontrado para plotar.")
        return

    # --- Calcula Médias e SEM ---
    processed_metrics = {}
    print("Calculando médias e erro padrão...")
    for metric_key, data_array in all_runs_data_interp.items():
        mean_value = np.mean(data_array, axis=0)
    
```

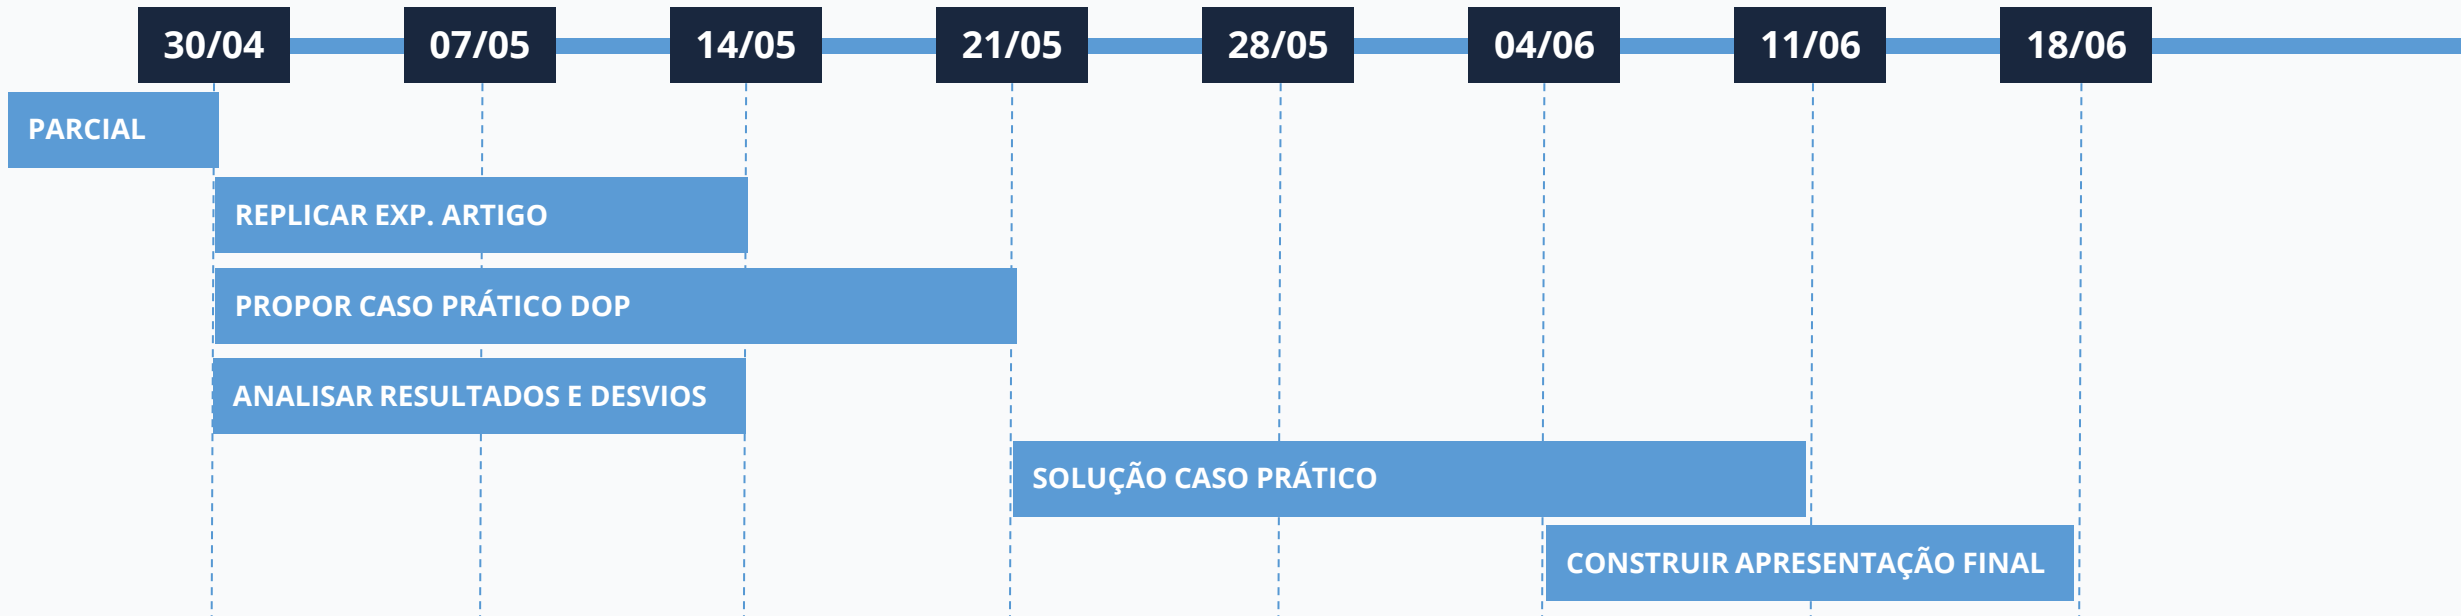


*Execução Teste: run_number = 5; change_frequency = 500; environment_number = 10

O QUE SERÁ FEITO ATÉ A APRESENTAÇÃO E CRONOGRAMA

Próximos Passos

1. Replicar experimento do artigo.
2. Analisar os resultados e possíveis desvios.
3. Propor um caso prático de otimização dinâmica.
4. Executar solução do caso prático.
5. Construir apresentação final.



REFERÊNCIAS

Yazdani, D., Yazdani, D., Yazdani, D., Omidvar, M. N., Gandomi, A. H., & Yao, X. (2023). A Species-based Particle Swarm Optimization with Adaptive Population Size and Deactivation of Species for Dynamic Optimization Problems. *ACM Transactions on Evolutionary Learning and Optimization*, 3(4), Article 14. <https://doi.org/10.1145/3604812>

OBRIGADO



EACH

campus capital



Escola de Artes, Ciências e Humanidades
Universidade de São Paulo